Mapeo de inundaciones con radar Sentinel-1 mediante U-Net: supervisión débil y generalización geográfica en Sen1Floods11

Julio Jesús Caqui Robles julio.caqui.r@uni.pe
Geyson Agustín Gonzales Cruz geyson.gonzales.c@uni.pe
Ronald Eduardo Portocarrero Hoyos ronald.portocarrero.h@uni.pe
Jhon Anderson Quispe Repuello jhon.quispe.r@uni.pe
Christian Salcedo Malaver christian.salcedo.m@uni.pe

Universidad Nacional de Ingeniería (UNI) · Facultad de Ingeniería Industrial y de Sistemas · Lima, Perú
Redes Neuronales y Aprendizaje Profundo · Examen parcial 2026-II · Pregunta 2
Código: https://github.com/AgustinG-C/flood-unet-sen1floods11-pre2

Resumen

Se implementa desde cero en PyTorch una U-Net que segmenta agua de inundación píxel a píxel a partir de las bandas VV y VH de Sentinel-1 (Sen1Floods11), y se estudia cómo combinar la etiqueta manual «dorada» (446 chips) con la etiqueta débil por umbralización, tres funciones de pérdida y tres decisiones arquitectónicas. En test con eventos vistos, el modelo final (Attention U-Net, solo etiqueta dorada, BCE+Dice) obtiene IoU 0.670 (F1 0.803). En Bolivia, excluida del entrenamiento, el IoU baja a 0.593 (brecha 0.078) y la omisión de agua sube de 19.0 % a 34.0 %. Mezclar chips débiles empeora el IoU en unos 0.045, pues la etiqueta débil coincide solo en 29–33 % con la manual; suprimir las conexiones de salto es lo que más daña. El exceso de omisión en Bolivia se concentra en píxeles de retrodispersión baja o intermedia, no en los brillantes del doble rebote. Se documentan cuatro tipos de fallo del SAR con ejemplos, y un bono con Sentinel-2 que eleva el IoU de 0.627 a 0.865 en chips sin nubes, con salvedades.

1 Motivación

Saber dónde está el agua en las horas posteriores a una inundación determina la eficacia de la respuesta de emergencia, pero las nubes de la tormenta inutilizan los sensores ópticos. El radar de apertura sintética (SAR) atraviesa las nubes y opera de noche, y es la herramienta de facto para el mapeo rápido; el problema es relevante en el Perú, por eventos como El Niño costero. Segmentar agua con aprendizaje profundo plantea dos desafíos: la **calidad de la supervisión** (etiquetas manuales confiables pero escasas frente a etiquetas automáticas abundantes pero ruidosas) y la **generalización geográfica** a regiones no vistas. Este trabajo los aborda con una U-Net propia, una ablación y una evaluación sobre un país excluido del entrenamiento.

2 Trabajos relacionados

SAR y agua. Sentinel-1 adquiere imágenes en banda C con polarizaciones VV y VH [6]. El agua en calma refleja el pulso de forma especular y aparece oscura, base de la umbralización clásica de Otsu [4], que falla ante *speckle*, sombra de radar, superficies lisas, suelo húmedo y doble rebote en vegetación o zonas urbanas inundadas. **Dataset.** Sen1Floods11 [1] reúne 11 eventos con S1 y S2 en chips de 512×512 a 10 m: 446 chips con etiqueta manual y 4 385 con etiqueta débil de S1 (otros 4 385 de S2); los chips dorados de Bolivia son el test geográfico y la métrica es el IoU, con omisión y comisión. **Modelos.** La U-Net [5] combina codificador, decodificador y conexiones de salto que preservan bordes; la Attention U-Net [3] filtra los saltos con compuertas $\alpha \in [0, 1]$. Con clases desbalanceadas, la BCE favorece al fondo y la pérdida Dice [2] optimiza el solapamiento directamente.

3 Metodología

3.1 Datos y preprocesamiento

Se usó la versión 1.1 del dataset. La **partición oficial** (`flood_train/valid/test_data.csv`) no contiene Bolivia: train 252, valid 89 y test 90 chips dorados, y los 15 chips dorados de Bolivia forman el test geográfico. De los 4 160 chips débiles sin Bolivia se muestrearon 1 500 (36 %) por cómputo; los débiles de Bolivia se excluyeron para evitar fuga geográfica. Las bandas en dB se recortan a $[-50, 1]$, se escalan como $(x + 50)/51$ y se estandarizan con la media $[0.6851, 0.5235]$ y desviación $[0.0820, 0.1102]$ del repositorio oficial. Los píxeles -1 y NaN se ignoran (valor 255) en pérdida y métricas. En entrenamiento se usan recortes de 256×256 con *flips* y rotaciones de $90°$; en evaluación, el chip completo.

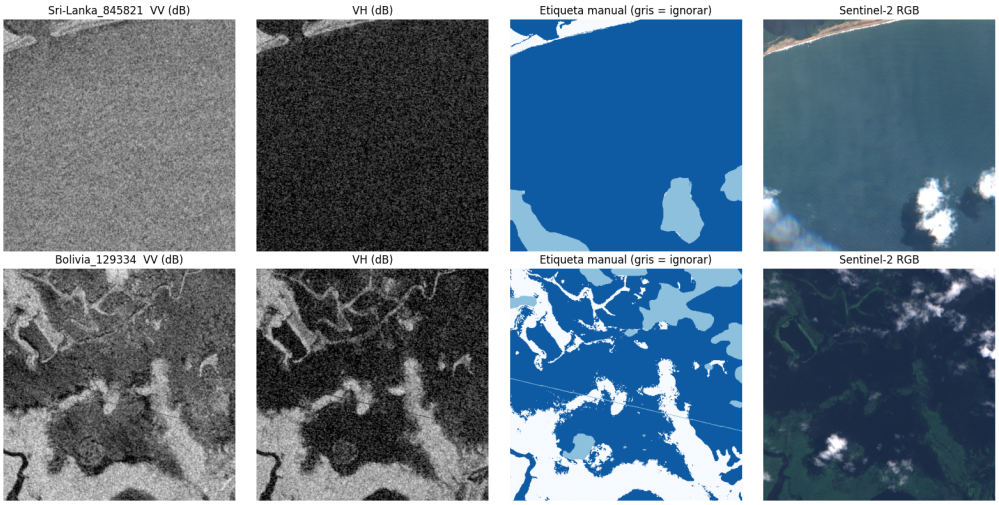


Figura 1: Chips Sri-Lanka_845821 (arriba) y Bolivia_129334 (abajo): VV, VH, etiqueta manual (azul oscuro = agua, celeste = ignorar) y Sentinel-2 RGB. Bolivia muestra agua oscura entre vegetación inundada, con etiquetas fragmentadas.

3.2 Arquitectura

La U-Net se implementó desde cero, sin copiar código de bibliotecas de segmentación ni usar pesos preentrenados. Tiene cuatro niveles $[32, 64, 128, 256]$, cuello de botella de 512 canales (dropout 0.1), bloques de dos convoluciones 3×3 con *BatchNorm* y ReLU, *max-pooling* 2×2, convoluciones transpuestas 2×2 y saltos por concatenación (Figura 2); 7.76 M de parámetros. Acepta 2 canales (VV, VH) o 8 en el bono, y entrega un logit de agua por píxel. Se parametrizan la profundidad, las compuertas de atención aditivas y la presencia de saltos.

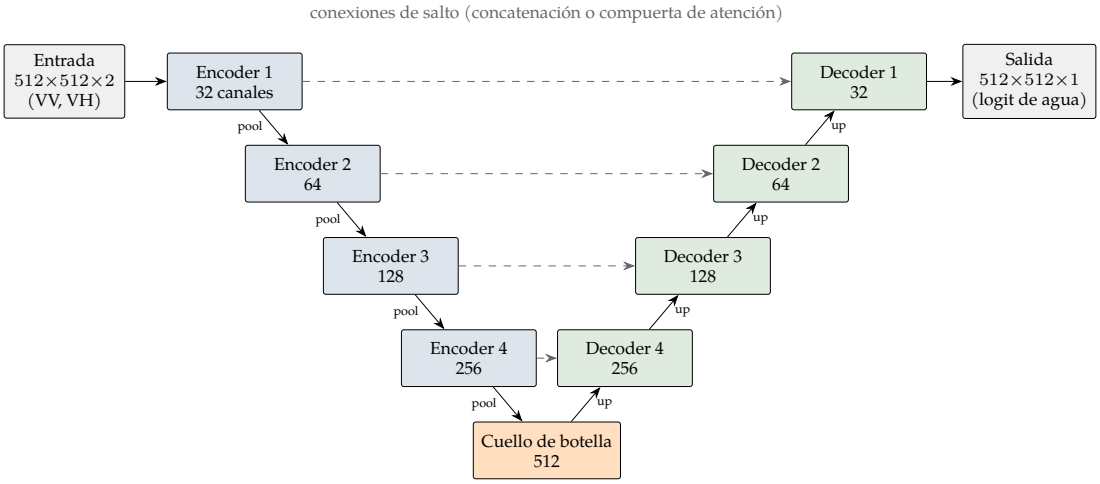


Figura 2: Diagrama de la U-Net (canales de salida por bloque). Las líneas discontinuas son los saltos: en C2 pasan por una compuerta de atención y en C3 se eliminan.

3.3 Pérdidas, ablación, entrenamiento y métricas

Se compararon tres pérdidas sobre píxeles válidos: $L_{\text{BCE}} = -\frac{1}{N}\sum_i [y_i \log p_i + (1-y_i)\log(1-p_i)]$, $L_{\text{Dice}} = 1 - \frac{2\sum p_i y_i + \epsilon}{\sum p_i + \sum y_i + \epsilon}$ ($\epsilon = 1$) y $L = 0.5 L_{\text{BCE}} + 0.5 L_{\text{Dice}}$. La ablación varía además la **fuente de supervisión** y el **diseño arquitectónico** (Tabla 1).

Tabla 1: Configuraciones de la ablación.

ID	Supervisión	Pérdida	Arquitectura
A1	Solo dorada	BCE+Dice	U-Net profundidad 4 (base)
A2	Dorada + débil (mezcla 50/50 por lote)	BCE+Dice	Base
A3	Débil → ajuste fino con dorada	BCE+Dice	Base
B1 / B2	Solo dorada	BCE / Dice	Base
C1 / C2 / C3	Solo dorada	BCE+Dice	Profundidad 3 / Attention U-Net / sin saltos

Todas las configuraciones usan el mismo presupuesto: AdamW (lr 10^{-3}, *weight decay* 10^{-4}), OneCycle, lote de 8 recortes, 1 500 pasos y precisión mixta en GPU de Colab (PyTorch 2.11); A3 usa 2 500 pasos con débiles y 800 de ajuste fino (lr 2×10^{-4}). Se evalúa la validación cada 100 pasos y se conserva el mejor *checkpoint*. Se usó una sola semilla. **El modelo final y el umbral de decisión se eligen solo con validación**; test y Bolivia nunca intervienen. El umbral se calibra barriendo 0.10–0.90 en validación. Se reportan sobre la clase agua IoU, F1,

precisión, recall, omisión ($= 1-$recall) y comisión ($= 1-$precisión), agrupadas por píxeles y promediadas por chip. La generalización geográfica evalúa el mismo modelo, entrenado sin Bolivia, solo en sus 15 chips dorados; la brecha es $\text{IoU}_{\text{test}} - \text{IoU}_{\text{Bolivia}}$.

3.4 Taxonomía de errores

Los píxeles erróneos se clasifican con reglas heurísticas sobre el VH (dB) y la distancia al contorno (Tabla 2); como proxy urbano se usa NDBI > 0 y NDVI < 0.2 de S2.

Tabla 2: Tipos de error y reglas.

Tipo	Regla	Interpretación física
FN: retrodispersión alta	Agua predicha como tierra, VH > -18 dB	Doble rebote (vegetación o zona urbana inundada), agua rugosa
FN: otros	Agua predicha como tierra, VH ≤ -18 dB	Agua oscura o moderada no detectada
FP: muy oscuro	Tierra predicha como agua, VH < -24 dB	Sombra de radar, superficies lisas
FP: moderado	Tierra predicha como agua, VH ≥ -24 dB	Suelo húmedo o saturado
Borde	Error a ≤ 2 píxeles del contorno	Píxeles mixtos, *speckle*

4 Resultados

4.1 Calidad de las etiquetas débiles

Comparando la etiqueta Otsu-S1 con la manual en los mismos chips, el IoU medio es 0.294 (train), 0.319 (valid), 0.332 (test) y 0.474 (Bolivia): en los eventos de entrenamiento la etiqueta débil comparte solo un tercio de su extensión con la manual, y sobreestima algo el agua (0.114 frente a 0.093 en train). Varía mucho por evento: 0.119 en Somalia, 0.140 en Pakistán y 0.242 en Ghana, frente a 0.523 en Mekong.

4.2 Estudio de ablación

Tabla 3: Ablación (clase agua, umbral 0.5, una semilla). En negrita, el mejor valor por columna.

Configuración	IoU val	IoU test	F1 test	Prec. test	Recall test	IoU Bolivia
A1 dorada, BCE+Dice	0.630	**0.676**	**0.807**	0.822	0.791	0.639
A2 dorada + débil	0.585	0.628	0.772	0.792	0.753	**0.696**
A3 débil → ajuste fino	0.629	0.657	0.793	0.824	0.765	0.594
B1 BCE	0.611	0.649	0.787	**0.851**	0.733	0.547
B2 Dice	0.630	0.675	0.806	0.819	**0.793**	0.611
C1 profundidad 3	0.623	0.668	0.801	0.817	0.785	0.584
C2 Attention U-Net	**0.631**	0.670	0.803	0.839	0.769	0.528
C3 sin saltos	0.595	0.622	0.767	0.773	0.761	0.640

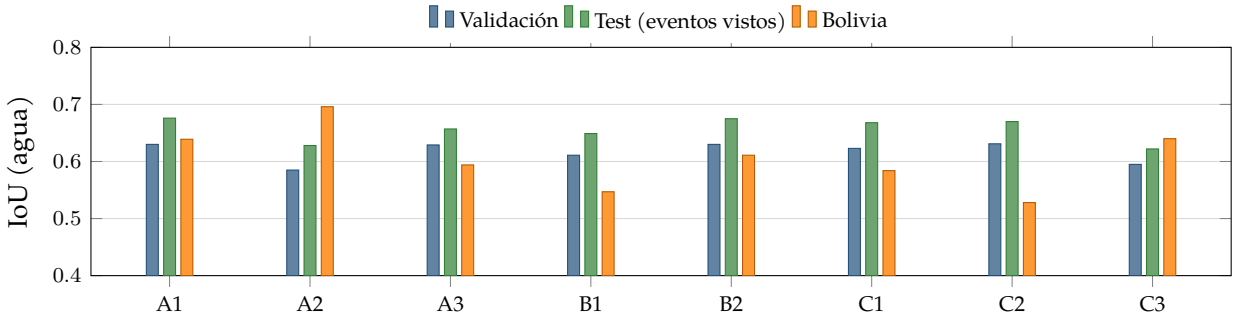


Figura 3: IoU por configuración y conjunto (eje vertical desde 0.4).

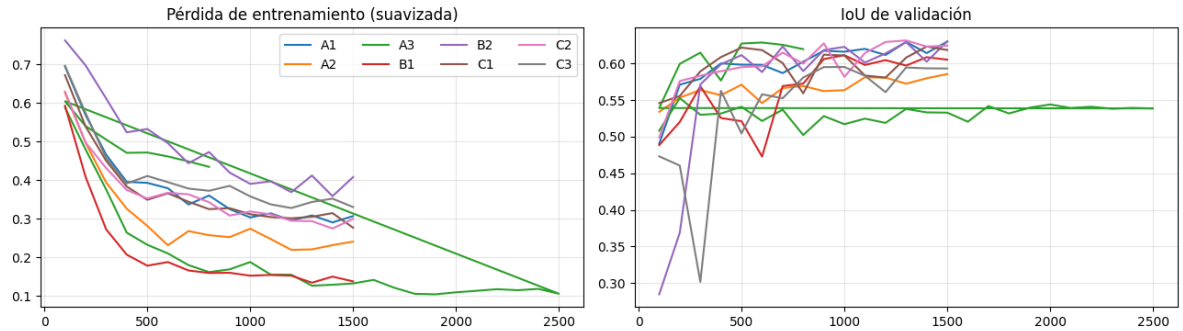


Figura 4: Pérdida de entrenamiento e IoU de validación. En A3 las curvas concatenan pre-entrenamiento con débiles (2 500 pasos) y ajuste fino (800).

(a) Dorada frente a dorada + débil. Mezclar chips débiles (A2) baja el IoU de validación de 0.630 a 0.585 y el de test de 0.676 a 0.628. El pre-entrenamiento con débiles (A3) iguala a A1 en validación (0.629) pero empeora test (0.657) y Bolivia (0.594); el modelo entrenado solo con etiqueta débil se estanca en ≈ 0.54 de IoU de validación (Figura 4), coherente con su baja concordancia (0.29–0.33). Aquí la etiqueta débil no aporta información útil en distribución, sino sesgos de la umbralización. El IoU de Bolivia de A2 (0.696) es el único resultado favorable, pero proviene de 15 chips y una semilla; configuraciones casi idénticas en validación varían en Bolivia entre 0.528 y 0.696, así que no es una mejora establecida. **(b) Pérdida.** Las pérdidas con Dice (0.630 y 0.675/0.676 en validación y test) superan a la BCE (0.611 y 0.649) en 0.02–0.03. La BCE tiene la mayor precisión (0.851) y el menor recall (0.733): favorece al fondo y omite más agua. Dice y la combinada son indistinguibles con una semilla. **(c) Arquitectura.** Quitar los saltos (C3) es lo más dañino: -0.035 en validación y -0.054 en test frente a A1. La profundidad 3 (C1) cuesta solo 0.007 y la atención (C2) no mejora de forma apreciable (0.631 frente a 0.630). **Significancia.** La validación fluctúa entre *checkpoints* 0.02–0.05 de IoU y hay una sola semilla; solo las diferencias ≥ 0.03 (saltos, débiles, BCE frente a Dice) son indicativas, y las de ≈ 0.01 entre A1, B2, C1 y C2 son empates. La regla fijada de antemano (mejor IoU de validación) eligió C2 por 0.001; no se eligió por test ni Bolivia.

4.3 Evaluación en distribución

El modelo final (C2, umbral 0.25 calibrado en validación, que sube su IoU de validación de 0.631 a 0.641) se evaluó en los 90 chips de test, de eventos vistos (Tabla 4, Figura 5).

Tabla 4: Métricas del modelo final en test.

	IoU	IoU/chip	F1	Precisión	Recall	Omisión	Comisión
Test (eventos vistos)	0.6704	0.4099	0.8027	0.7954	0.8100	19.0 %	20.5 %

Test (eventos vistos)

	Pred. no agua	Pred. agua
Real: no agua	17 405 016 (97.1 %)	523 935 (2.9 %)
Real: agua	477 835 (19.0 %)	2 037 173 (81.0 %)

Bolivia (región no vista)

	Pred. no agua	Pred. agua
Real: no agua	2 321 476 (97.8 %)	51 057 (2.2 %)
Real: agua	153 868 (34.0 %)	298 033 (66.0 %)

Figura 5: Matrices de confusión en píxeles (porcentaje por fila).

Comentario de la matriz. El agua es el 12.3 % de los píxeles válidos, por lo que la exactitud (cercana al 95 %) engaña y se usan IoU y F1. El modelo detecta 81.0 de cada 100 píxeles de agua y pierde 19.0; de cada 100 que marca como agua, 20.5 son falsos. Ambos errores están casi balanceados (478 mil FN frente a 524 mil FP), de modo que a este umbral no es ni conservador ni optimista; como omitir agua suele ser más costoso en emergencias, un umbral bajo como 0.25 es razonable. El IoU por chip es más débil en Pakistán (0.179), Somalia (0.297) y Ghana (0.322), los eventos de menor concordancia Otsu-manual; Somalia tiene además el menor contraste VH agua-tierra (3.1 dB frente a 6.6 dB de promedio) y Pakistán el suelo más árido (NDVI 0.15). El IoU por chip (0.410) es menor que el agrupado (0.670) porque los chips con poca agua tienen IoU inestable y pesan igual; 4 chips sin agua ni predicción quedan sin IoU definido.

4.4 Generalización geográfica: Bolivia

Tabla 5: Test $\rightarrow$ Bolivia (modelo final, umbral 0.25).

	IoU	IoU/chip	F1	Precisión	Recall	Omisión	Comisión
Test	0.6704	0.4099	0.8027	0.7954	0.8100	19.0 %	20.5 %
Bolivia	0.5926	0.3709	0.7442	0.8537	0.6595	34.0 %	14.6 %
Brecha	0.0778	0.0391	0.0585	-0.0583	0.1505	+15.0 pp	-5.9 pp

La brecha de IoU es 0.078 (11.6 % relativo) y se debe enteramente al **recall**: en Bolivia el modelo es más conservador. Depende del umbral: con 0.5 el IoU de Bolivia es 0.528 (brecha 0.142), y el umbral 0.25, calibrado solo con validación, la reduce a 0.078, lo que indica probabilidades de agua sistemáticamente más bajas en Bolivia. Por chip es muy desigual: el IoU va de 0.00 a 0.83 (mediana 0.39), con 5 chips bajo 0.10 y 4 sobre 0.70; el intervalo bootstrap aproximado de su media es $[0.22, 0.52]$. Con 15 chips la estimación puntual es incierta, aunque la dirección del efecto es coherente en todas las pruebas.

Tabla 6: Hipótesis sobre la brecha y evidencia.

Hipótesis	Prueba	Evidencia	Veredicto
H1. Desplazamiento radiométrico VV/VH	Wasserstein de VH, medias por evento, histogramas	VH medio de agua -21.4 dB y de tierra -15.1 dB en Bolivia frente a -23.2 y -16.6 dB en los demás ($+1.7$ y $+1.5$ dB), con contraste similar (6.3 frente a 6.6 dB); eventos más cercanos: Sri-Lanka (W 0.64/0.59), India, Paraguay	Parcialmente confirmada
H2. Geometría de adquisición (órbita)	IoU por chip en test según órbita	Ascendente 0.391 (38 chips), descendente (la de Bolivia) 0.425 (48 chips)	No explica la brecha por sí sola
H3. Vegetación inundada y doble rebote	FN y FP por rango de VH; NDVI del suelo seco	NDVI de Bolivia 0.558, el mayor de 11 (media de los demás 0.40). FN con VH ≥ -18 dB: 79 % y 95 % frente a 81 % y 96 % en test (igual). FN con VH < -26 dB: 15.2 % frente a 1.2 %; en $[-26, -22)$: 29.3 % frente a 9.2 %; en $[-22, -18)$: 58.8 % frente a 45.5 %	Doble rebote refutado como causa del exceso de FN; vegetación densa plausible, no demostrada
H4. Prevalencia de agua y etiqueta	Fracción de agua por evento; concordancia Otsu-manual	Bolivia 0.170, tercero de 11 (rango 0.046–0.236); Otsu-manual 0.474, segunda más alta	No explica la brecha

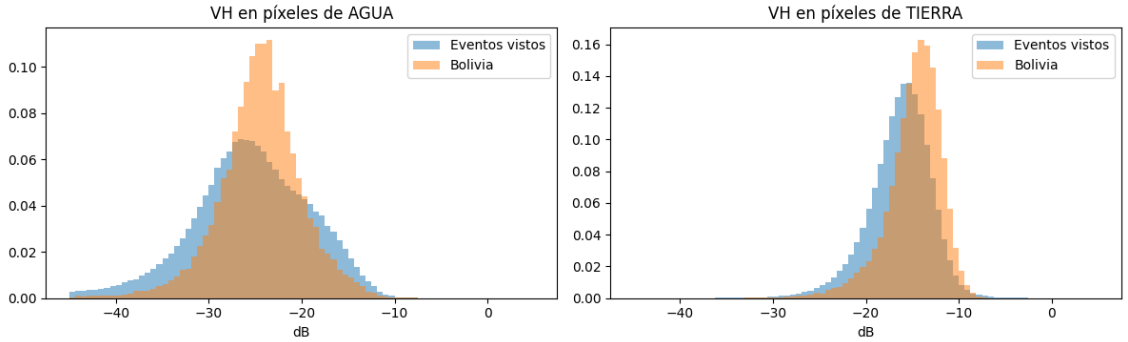
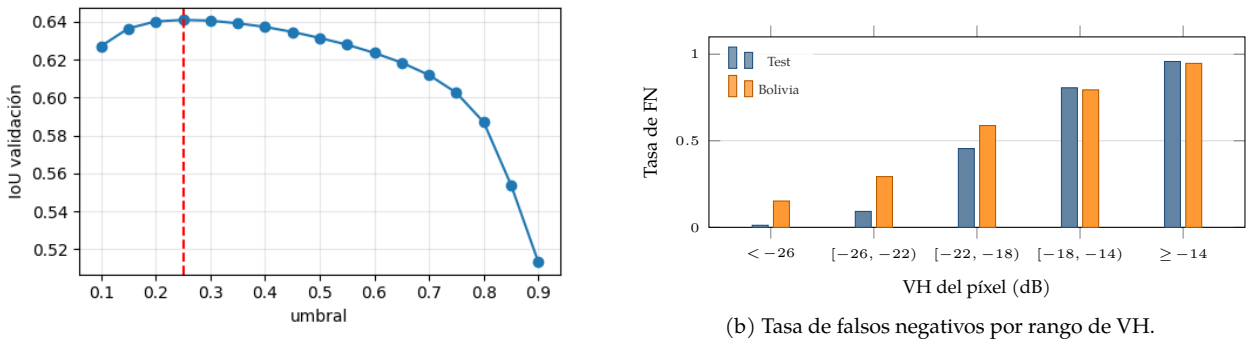


Figura 6: Distribución de VH en píxeles de agua (izquierda) y tierra (derecha): eventos vistos frente a Bolivia.



(a) IoU de validación según el umbral; la línea roja marca 0.25.

(b) Tasa de falsos negativos por rango de VH.

Figura 7: Calibración del umbral (a) y omisión por retrodispersión (b).

Interpretación. (i) La evidencia más fuerte está en H3 pero en sentido contrario al esperado: el exceso de omisión **no** aparece en los píxeles brillantes (VH ≥ -18 dB; la tasa de FN es igual a la de test) sino en los oscuros y moderados; incluso el agua muy oscura (< -26 dB) se omite en 15.2 % frente a 1.2 % en test. Por eso los FN con VH ≤ -18 dB son el 47.6 % de los errores de Bolivia (Tabla 7). (ii) Coherente con H1, agua y tierra de Bolivia son ≈ 1.6 dB más brillantes que el promedio de los eventos de entrenamiento, con contraste similar; un modelo que aprendió fronteras absolutas de retrodispersión en eventos más oscuros asignaría menos probabilidad de agua a Bolivia, y explicaría que bajar el umbral reduzca la brecha casi a la mitad. Es una hipótesis compatible con los datos, no un resultado demostrado. (iii) H2 no se sostiene (el ángulo de incidencia local no está en el dataset, así que no puede descartarse) y (iv) H4 se descarta. (v) El NDVI se mide en tierra seca, no en zonas inundadas, así que no prueba por sí solo vegetación inundada. Separar estas causas requeriría validar dejando fuera un país distinto cada vez.

4.5 Análisis cualitativo de fallos del SAR

Tabla 7: Píxeles erróneos por tipo (test: 1 001 770; Bolivia: 204 925).

Tipo	Test (px)	Test (%)	Bolivia (px)	Bolivia (%)
Borde (píxeles mixtos)	422 537	42.2	72 555	35.4
FN: retrodispersión alta (VH > -18)	101 625	10.1	9 107	4.4
FN: otros (VH ≤ -18)	131 723	13.1	97 595	**47.6**
FP: muy oscuro (VH < -24)	168 877	16.9	8 551	4.2
FP: moderado	177 008	17.7	17 117	8.4

El borde domina en test (42.2 %), pero está inflado: las máscaras manuales de vegetación inundada son muy fragmentadas y la banda de 2 píxeles cubre gran parte del agua. Sin el borde, en test los FP (34.6 %) superan a los FN (23.2 %); en Bolivia ocurre lo contrario (FN 52.0 %, FP 12.6 %). Solo el 3.0 % de los FN de test y el 2.7 % en Bolivia caen sobre superficies construidas o desnudas (proxy S2), así que el doble rebote urbano explica poco de la omisión. Cada figura muestra, de arriba abajo, tres chips (recorte de 128×128): VH, Sentinel-2 RGB, etiqueta, predicción y píxeles del error en rojo.

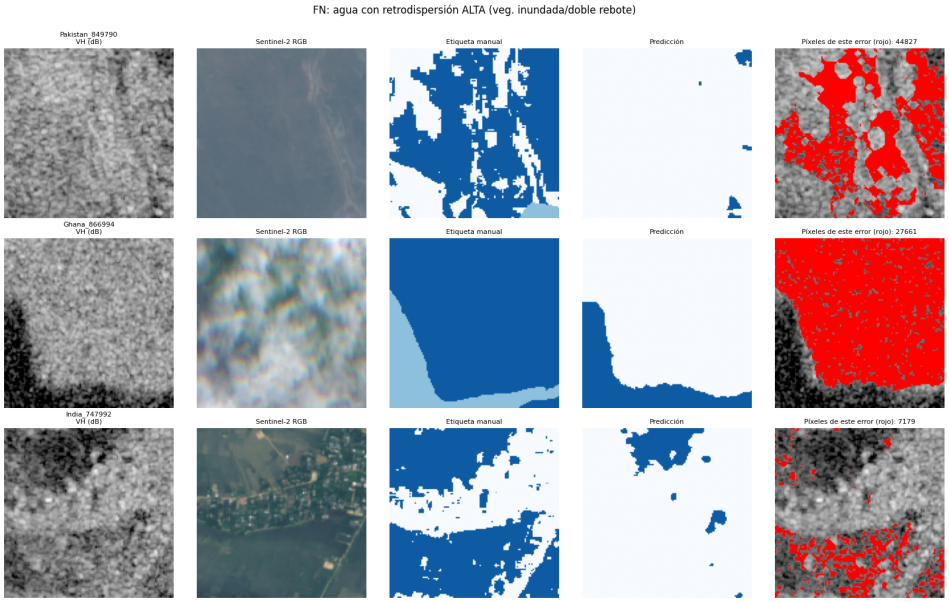


Figura 8: Tipo 1, FN con VH alto: Pakistan_849790 (44 827 px), Ghana_866994 (27 661) e India_747992 (7 179).

Tipo 1. Omisión con retrodispersión alta (doble rebote). Pakistan_849790 es una zona extensa inundada con VH brillante y granuloso, casi sin predicción de agua. En Ghana_866994 el S2 está cubierto de nubes y la etiqueta marca una gran extensión como agua aunque el VH es brillante: probable etiqueta inconsistente con la evidencia SAR. India_747992 muestra un poblado inundado con VH brillante. Con estructuras verticales (casas, troncos) el pulso rebota agua–estructura–sensor y la señal supera a la del agua abierta; el modelo, que asocia agua con oscuridad, la clasifica como tierra (India es coherente con este mecanismo; Ghana, más bien problema de etiqueta). Es el tipo con mayor omisión por píxel (79–96 % con VH ≥ -18 dB) pero aporta 10.1 % de los errores en test y 4.4 % en Bolivia. *Mitigación:* coherencia o polarimetría, máscaras de vegetación o urbanas, fusión con óptico.



Figura 9: Tipo 2, FP muy oscuros: Pakistan_70625 (26 723 px), USA_595451 (18 292) y Pakistan_694942 (14 382).

Tipo 2. Falsos positivos por sombra y superficies lisas. En Pakistan_70625 los campos desnudos (beige en S2) tienen VH muy oscuro y se predice una gran mancha de agua donde la etiqueta solo tiene un canal; USA_595451 es un campo homogéneo oscuro con solo parches de agua; en Pakistan_694942 el S2 está velado y la etiqueta vacía. Las superficies lisas (suelo labrado, arena seca) reflejan el pulso de forma especular y son tan oscuras como el agua, igual que la sombra de radar; con solo VV y VH el modelo no las separa. Solo en Pakistan_70625 el contexto óptico apoya suelo desnudo; en los otros no es concluyente y no se descarta agua sin etiquetar. Es 16.9 % del error en test y 4.2 % en Bolivia. *Mitigación:* DEM o HAND como canal, ángulo de incidencia, máscara de pendiente.

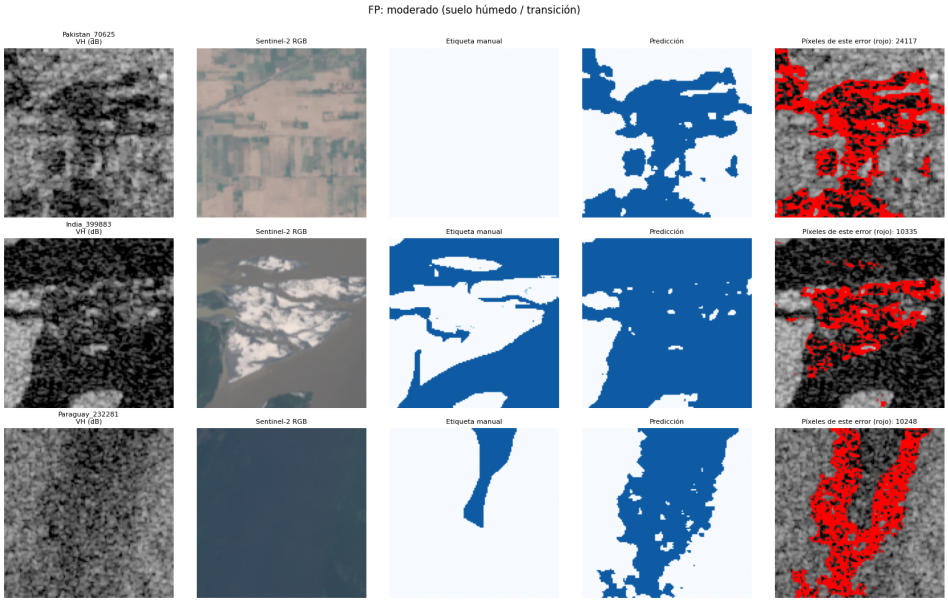


Figura 10: Tipo 3, FP moderados: Pakistan_70625 (24 117 px), India_399883 (10 335) y Paraguay_232281 (10 248).

Tipo 3. Suelo húmedo frente a agua abierta. En Pakistan_70625 se predice agua en parcelas de riego; en India_399883 (río con bancos de arena) sobre arena húmeda de la transición; en Paraguay_232281 la predicción ensancha un canal que la etiqueta marca más estrecho. El suelo saturado, los campos irrigados y la arena húmeda tienen retrodispersión cercana al umbral del agua y la separabilidad es baja. Es 17.7 % del error en test. *Mitigación:* series temporales (cambio frente a imagen seca), umbral por región, más contexto espacial.

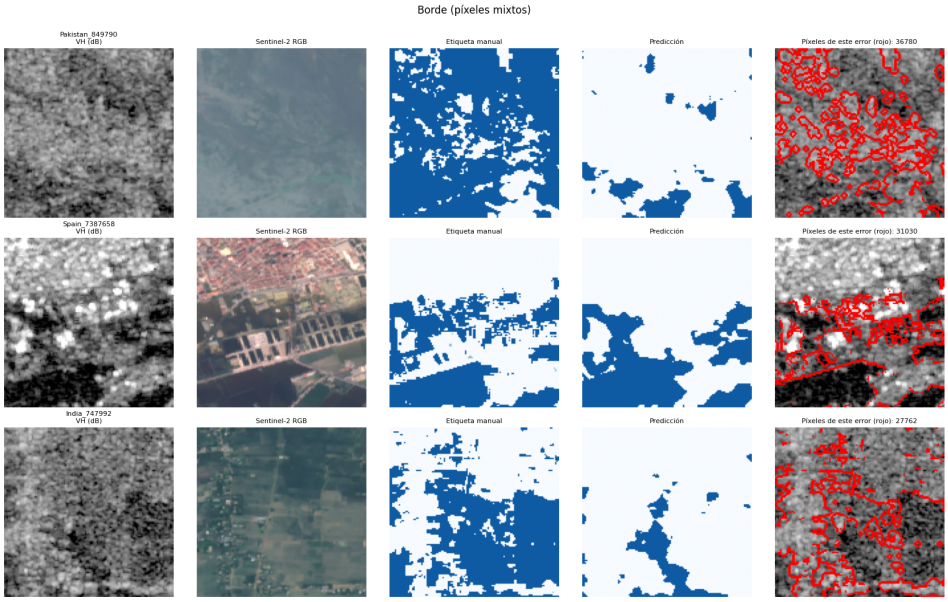


Figura 11: Tipo 4, errores de borde: Pakistan_849790 (36 780 px), Spain_7387658 (31 030) e India_747992 (27 762).

Tipo 4. Bordes. Spain_7387658 muestra el límite entre un casco urbano y campos inundados con etiquetas muy fragmentadas; los otros dos son vegetación inundada. En el contorno coexisten agua y tierra en un píxel de 10 m y el *speckle* desplaza el borde; es un error en parte inherente a la resolución y a la fragmentación de la etiqueta. *Mitigación:* pérdida con peso en bordes, filtrado de *speckle*.

Error dominante en Bolivia. El 47.6 % de sus errores son FN con VH ≤ -18 dB lejos del borde (97 595 px, el 21.6 % del agua de Bolivia): no es doble rebote porque el VH es oscuro o moderado, y no se incluye galería propia de esa categoría. Las reglas son heurísticas y algunos ejemplos podrían encajar en más de una categoría.

4.6 Bono: fusión SAR + Sentinel-2

Se añadieron las bandas B2, B3, B4, B8, B11 y B12 a VV y VH (8 canales), solo en chips sin nubes. Sin máscara de calidad, la nubosidad se estimó con una heurística (azul > 0.25 o cirros altos en B10); con umbral del 2 % de píxeles quedaron 130 chips de entrenamiento, 42 de validación, 52 de prueba y 6 de Bolivia. Ambos modelos (Attention U-Net, BCE+Dice) usan los mismos chips, pasos, semilla y umbral 0.25.

Tabla 8: Solo-SAR frente a SAR + Sentinel-2 (chips sin nubes).

Modelo	IoU val	IoU test	F1 test	Prec. test	Recall test	IoU Bolivia
Solo SAR (2 canales)	0.664	0.627	0.771	0.798	0.745	0.782
SAR + S2 (8 canales)	**0.859**	**0.865**	**0.928**	**0.916**	**0.939**	**0.894**

La fusión sube el IoU de test de 0.627 a 0.865 ($+0.238$; $+0.196$ en validación; $+0.112$ en los 6 chips de Bolivia). Hay que leerla con cautela: (1) el 0.627 se mide en otros 52 chips y con 130 de entrenamiento, no es comparable con el 0.670 del modelo completo; (2) el agua es muy separable en el óptico, y si las etiquetas manuales se hicieron con apoyo de imágenes ópticas, el modelo con S2 vería la misma evidencia que el anotador (debe verificarse en [1]); (3) hay una semilla, 6 chips en Bolivia y un umbral compartido calibrado para el modelo solo-SAR; (4) solo aplica donde hay óptico sin nubes, lo contrario del escenario de emergencia. La conclusión sólida es que el óptico aporta mucha información cuando existe; el valor exacto de la mejora es incierto.

5 Discusión crítica y conclusiones

Conclusiones. (1) *Supervisión:* la etiqueta débil coincide solo 29–33 % con la manual y mezclarla baja el IoU unos 0.045; la mejor estrategia fue usar solo los 446 chips dorados. (2) *Pérdida y arquitectura:* Dice supera a BCE en 0.02–0.03 y en recall; los saltos son lo más importante (-0.035 a -0.054 si se quitan); profundidad 3 y atención no se distinguen de la base. (3) *Generalización:* el IoU cae de 0.670 a 0.593 en Bolivia por pérdida de recall; el exceso de omisión se concentra en VH oscuro o moderado y es compatible con un desplazamiento radiométrico de ≈ 1.6 dB, no con doble rebote. (4) *Fallos:* se documentaron cuatro tipos con ejemplos y mitigaciones. (5) *Bono:* el óptico mejora mucho el IoU donde está disponible.

Limitaciones. (i) Bolivia aporta solo 15 chips (IoU por chip de 0.00 a 0.83), así que la brecha es incierta. (ii) Hay una sola semilla y las fluctuaciones de validación (0.02–0.05) son comparables a varias diferencias de la ablación; el modelo final se eligió por 0.001. (iii) Solo se usó el 36 % de los chips débiles; el resultado sobre la supervisión débil podría cambiar con otro muestreo o con filtrado. (iv) Las reglas de error y la detección de nubes son heurísticas; no se dispuso de DEM, ángulo de incidencia local ni máscara urbana. (v) La ablación usa umbral 0.5 y el modelo final 0.25, por lo que no son comparables fila a fila (el IoU de Bolivia de C2 es 0.528 con

0.5 y 0.593 con 0.25). (vi) En el bono se comparten umbral y semilla. **Trabajo futuro:** DEM/HAND e incidencia local como canales; validación dejando fuera un país distinto cada vez y varias semillas; filtrado de la etiqueta débil por confianza; calibrar el umbral con una muestra de la región objetivo. El código, los *logs* y los resultados están en https://github.com/AgustinG-C/flood-unet-sen1floods11-pre2.

Referencias

[1] Bonafilia, D., Tellman, B., Anderson, T., & Issenberg, E. (2020). Sen1Floods11: a georeferenced dataset to train and test deep learning flood algorithms for Sentinel-1. *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops* (*CVPRW*), 835–845. doi:10.1109/CVPRW50498.2020.00113

[2] Milletari, F., Navab, N., & Ahmadi, S.-A. (2016). V-Net: Fully convolutional neural networks for volumetric medical image segmentation. *Fourth International Conference on 3D Vision* (*3DV*), 565–571.

[3] Oktay, O., Schlemper, J., Le Folgoc, L., Lee, M., Heinrich, M., Misawa, K., et al. (2018). Attention U-Net: Learning where to look for the pancreas. *1st Conference on Medical Imaging with Deep Learning* (*MIDL*). arXiv:1804.03999.

[4] Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), 62–66. doi:10.1109/TSMC.1979.4310076

[5] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention* (*MICCAI*), LNCS 9351, 234–241. arXiv:1505.04597.

[6] Torres, R., Snoeij, P., Geudtner, D., Bibby, D., Davidson, M., Attema, E., et al. (2012). GMES Sentinel-1 mission. *Remote Sensing of Environment*, 120, 9–24. doi:10.1016/j.rse.2011.05.028